


Квантизация моделей машинного обучения

Выполнил: Рыжов А.С

23-ИВТ-5



Зачем нужно оптимизировать модель, если и так все работает?

При разворачивании модель на устройстве, которое будет ее обрабатывать, встанет множество проблем.

Сценарии использования

Увеличение
пропускной
способности


Развертывание
моделей на edge-
устройствах

Уменьшение размера
модели для
ускоренного
обновления модели

Для оборудования с
ограничениями или
оптимизацией для
операций с
фиксированной точкой.


Также для аппаратных
ускорителей
специального
назначения.

Методы оптимизации




- Pruning
- Quantization
- Knowledge distillation
- Weight clustering
- OpenVino, TensorRT .


Pruning



Пример



6 inputs, 6 neurons (including 2 outputs), 32 connections



6 inputs, 5 neurons (including 2 outputs), 24 connections

Исходно:

$$[6 \cdot 4] + [4 \cdot 2] = 24 + 8 = 32 \text{ MLA}$$

=> держать в памяти 32 параметра.


После удаления красного нейрона:

$$[6 \cdot 3] + [3 \cdot 2] = 18 + 6 = 24 \text{ MLA}$$

Почему не строить сразу малую сеть?

Большие модели легче обучать — у них больше пространство поиска решений, а малые часто не достигают той же точности.


Quantization



Квантование модели — это популярный метод оптимизации глубокого обучения, при котором данные модели — как параметры сети, так и активации — преобразуются из представления с плавающей запятой в представление с более низкой точностью, например, с использованием 8-битных целых чисел

Преимущества

1. Ускорение вычислений
2. Экономия памяти и энергии
3. Оптимизация передачи данных



Методы квантования

Снижение точности параметров может легко навредить точности модели. 32-битный тип с плавающей точкой может представлять примерно **4 миллиарда** чисел в интервале $[-3.4e38, 3.40e38]$.




Figure 1. 8-bit signed integer quantization of a floating-point tensor x_f . The symmetric dynamic range of $x_f[-amax, amax]$ is mapped through quantization to $[-128, 127]$.

Как работает квантование?

1. Линейное квантование

Float32 -> int8 по формуле, где

- s — масштабный коэффициент (scale),
- z — смещение (zero-point),
- α_q, β_q — границы диапазона (int8: от -128 до 127).

$$x_q = \text{round}\left(\frac{1}{s}x + z\right)$$

Получаем коэффициенты

$$\beta = s * (\beta_q + z)$$

$$\alpha = s * (\alpha_q + z)$$

Где

β — это верхняя граница диапазона x ,

β_q — верхняя граница диапазона x_q ,

α — нижняя граница диапазона x ,

α_q — нижняя граница диапазона x_q .

Откуда

$$s = \frac{\beta - \alpha}{\beta_q - \alpha_q} \quad z = \frac{\alpha\beta_q - \beta\alpha_q}{\beta - \alpha}$$

Пример:

входные значения лежат в диапазоне x $[-500, 2050]$ с типом данных `fp32`.

Нам необходимо преобразовать в `signed int8`, который лежит в диапазоне x_q

$[-128, 127]$. Отсюда $s = (2050 + 500)/(127 + 128) = 10$,

а $z = (-500*127 - 2050*(-128))/(2050+500)=78$.

Когда мы имеем коэффициенты преобразования, мы можем рассчитать любое входное значение:

$$\text{при } x = 177 \Rightarrow x_q = \text{round}\left(\frac{177}{10} + 78\right) = \text{round}(95.7) = 96$$

Отсечение (clipping)

Если значение выходит за допустимые границы, оно принудительно ограничивается (clip).

$$x_q = \text{clip}(\text{round}(\frac{1}{s}x + z), \alpha_q, \beta_q)$$



Разные типы квантования

- **float32 → int8**
 - Максимальное ускорение, но возможна потеря точности.
- **float32 → float16**
 - Меньше ускорения, но почти без потерь точности.
- **Гибридные схемы** (например, веса в int8, активации в float16).

Квантование на практике

- **PTQ - Post-Training Quantization - Квантование после обучения**
- **QAT - Quantization-Aware Training - Обучение с учетом квантования**

Knowledge distillation (Дистилляция значений)



Как это работает?

Учитель - уже обученная модель (миллиард параметров)


Ученик - компактная сеть. Учится на "мягких" вероятностях учителя.

$$p_i = \frac{\exp(\frac{z_i}{T})}{\sum_j \exp(\frac{z_j}{T})}$$

Чем это лучше обычного обучения?


Учитель уже знает сложные закономерности, а ученик перенимает это

Без дистилляции маленькая модель не сможет сама перенять такие нюансы




Как это реализуется?

Пример установления
соответствия --->




Weight clustering (Кластеризация весов)



Кластеризация весов — это метод уменьшения объема хранения вашей модели путем замены многих уникальных значений параметров меньшим количеством уникальных значений.

Как это работает?



Пользователь задаёт число кластеров (например, 4).

Алгоритм группирует близкие веса и находит их "центры" (центроиды).

Каждый вес заменяется на индекс его центроида (например, 0, 1, 2, 3).

Теперь храним:

- 4 центроида (float32).
- 16 индексов (например, 2-битных).

Преимущества кластеризации весов

- Сокращение размеров модели
- Дополнительное сжатие
- Сохранение точности

Фреймворки для оптимизации

- 1. OpenVINO (Intel)

OpenVINO toolkit (или Intel Distribution of OpenVINO Toolkit) — это открытый бесплатный набор инструментов, который помогает ускорить разработку высокопроизводительных решений для использования в различных видеосистемах.

TensorRT

TensorRT — специальный фреймворк, который максимально утилизирует мощь видеокарты для нейронных сетей.

Приложения на основе TensorRT работают до 40 раз быстрее, чем платформы, использующие только CPU. С помощью TensorRT вы можете оптимизировать модели нейронных сетей, обученные во всех основных средах, провести квантование и развернуть решение в гипермасштабируемых центрах обработки данных, edge-девайсах или автомобильных платформах.



Спасибо
за
ВНИМАНИЕ!